

数据预处理技术 复习资料

一、判断题

1. Numpy 中的 T 属性可以用于数组的转置操作。 (✓)
2. 使用 stack() 方法时, 必须指定 axis 参数的值。 (✗)
3. 在 Numpy 中, itemsize 属性表示数组中每个元素的存储字节数。 (✓)
4. swapaxes() 方法用于交换 Numpy 数组的两个轴。 (✓)
5. 使用 Numpy 的 zeros() 函数可以创建一个所有元素都是 0 的 ndarray, 且元素的数据类型默认为 float64。 (✓)
6. pandas 库是专门为数据分析而设计的, 不依赖于其他任何库。 (✗)
7. Series 对象的数据类型可以是整数、字符串或浮点数等, 但索引必须是整数类型。 (✗)
8. 在创建 Series 对象时, 如果不指定 index 参数, pandas 会自动生成从 0 开始的整数索引。 (✓)
9. DataFrame 对象只能有一组索引, 即行索引。 (✗)
10. 使用 pd.DataFrame() 函数创建 DataFrame 对象时, data 参数可以是 ndarray、dict、list 或可迭代对象。 (✓)
11. groupby() 方法中的 sort 参数默认为 True, 表示对分组索引进行排序。 (✓)
12. 堆叠合并数据中的 ignore_index=True 参数会忽略合并结果的索引, 并生成新的索引。 (✓)
13. 数据预处理阶段的任务包括数据清理、数据集成、数据变换, 但不包括数据挖掘。 (✓)
14. groupby() 方法中的 axis 参数默认为 0, 表示沿列方向进行分组操作。 (✓)
15. pivot_table() 方法是 pandas 中用于实现数据透视表功能的方法。 (✓)
16. 堆叠合并数据只能沿着行方向进行, 不能沿着列方向。 (✗)
17. pandas 中的 merge() 方法仅支持主键合并数据, 不支持其他类型的合并。 (✗)
18. 数据清理主要解决的数据问题包括数据缺失、数据重复和数据异常, 但不包括数据冗余。 (✓)
19. 在 pandas 中, drop() 方法可以用于删除数据, 包括根据指定的行标签索引或列标签索引删除异常值。 (✓)
20. pandas 中 plot() 函数用于绘制箱形图, 且默认会显示网格线。 (✗)

二、单选题

31. 在数据清理中, 重复值主要有哪两种处理方式?
A: 删除和填充
B: 插补和替换
C: 删除和保留
D: 替换和忽略
32. 填充缺失值时, 'pad' 或 'ffill' 方法的含义是什么?
A: 使用缺失值后面的有效值填充
B: 使用缺失值前面的有效值填充
C: 使用众数填充
D: 使用随机数填充
33. 数据清理的主要目的是什么?
A: 增加数据量
B: 提高数据质量

- C: 降低数据分析成本
 - D: 减少数据存储空间
34. 在使用 `pd.read_sql()` 函数从数据库中读取数据时, `sql` 参数指的是什么?
- A: 数据库连接字符串
 - B: 要执行的 SQL 查询语句
 - C: 数据库的名称
 - D: 表的名称
35. 使用 `read_json()` 函数读取 JSON 文件时, `orient` 参数用于指定什么?
- A: 文件的编码格式
 - B: 文件的路径
 - C: JSON 字符串的格式
 - D: 列索引
36. `head()` 方法默认显示数据的前几行?
- A: 1 行
 - B: 3 行
 - C: 5 行
 - D: 10 行
37. `sort_values()` 方法中的 `by` 参数用于指定根据哪个索引名进行排序?
- A: 行索引名
 - B: 列索引名
 - C: 自动生成的整数索引
 - D: 时间戳索引
38. 下列哪个选项不是创建 Series 对象时可以使用的数据类型?
- A: ndarray
 - B: List
 - C: Dict
 - D: set
39. DataFrame 对象具有几组索引?
- A: 1 组
 - B: 2 组
 - C: 3 组
 - D: 4 组
40. Numpy 中, `unique()` 函数的作用是什么?
- A: 对数组进行排序
 - B: 查找数组中的唯一元素
 - C: 生成随机数
 - D: 计算数组的平均值
41. 使用 Numpy 的哪个函数可以快速创建一个全零的 ndarray?
- A: Zeros
 - B: Ones
 - C: Empty
 - D: identity
42. 在 Numpy 中, 使用 `stack` 方法组合多个数组时, 哪个参数用于指定新轴的位置?
- A: Arrays

B: Axis

C: Shape

D: dtype

43. 在 Numpy 中，使用哪个函数可以实现数组的排序？

A: sort()

B: order()

C: arrange()

D: rank()

44. 下列哪个属性表示 ndarray 的维数？

A: Shape

B: Ndim

C: Size

D: dtype

45. 在堆叠合并数据中，如果设置 ignore_index=True，合并结果会发生什么变化？

A: 保留原索引

B: 生成新的索引

C: 删除所有索引

D: 不影响索引

三、填空题

51. unique 函数在 Numpy 中用于查找数组中的__唯一__元素。

52. describe 方法用于一次性描述数据的多个统计指标，如平均值、最大值、最小值等，而不用逐个调用__统计__函数。

53. head 方法默认显示数据的前__5__行。

54. DataFrame 对象有两组索引，分别是行索引和__列索引__。

55. pandas 中用于合并数据的函数或方法主要包括__主键__合并数据、重叠合并数据和堆叠合并数据等。

56. 数据集成是将多个数据源的数据合并到一个数据源，形成__一致__的数据存储的过程。

57. 箱型图是一种用于显示一组数据分散情况的统计图，它通常由上边缘、上四分位数、中位数、下四分位数、下边缘和__异常值__组成。

58. pandas 中提供了删除缺失值的方法__dropna__，它用于删除缺失值所在的一行或一列数据。

59. 处理异常值之前，需要先辨别哪些值是“真异常”和“伪异常”，再根据实际情况正确地处理__异常__值。

60. 重复值主要有两种处理方式：删除和保留，其中删除重复值是比较常见的方式，目的在于保留__唯一__的数据记录。